## ΔΟΜΕΣ ΔΕΔΟΜΕΝΩΝ - EAPINO EΞΑΜΗΝΟ 2023-2024 PROJECT

Τσάλα Ζαφειρία	1084963	up1084963@ac.upatras.gr	2° έτος
Γκύλλης Κων/νος	1100526	up1100526@ac.upatras.gr	2° έτος
Μήλιος Θεόδωρος	1100624	up1100624@ac.upatras.gr	2° έτος
Τεμπονέρας Γεώργιος	1104775	up1104775@ac.upatras.gr	2º έτος

#### PART I – SORTING AND SEARCHING ALGORITHMS

Στο παρόν project, εργαζόμαστε με δεδομένα που τα αντλούμε από το <a href="https://www.stats.govt.nz/large-datasets/csv-files-for-download/">https://www.stats.govt.nz/large-datasets/csv-files-for-download/</a>. Κατεβάζουμε το ζητούμενο αρχείο το οποίο είναι σε csv μορφή και το μετατρέπουμε σε txt, για να χρησιμοποιήσουμε τις εγγραφές που περιέχει στους κώδικες μας. Δουλεύουμε σε γλώσσα C++.

Το txt μας από το οποίο διαβάζουμε τα δεδομένα μας είναι της μορφής: <Period>,<Birth | Death>,<Region>,<count>

### ΕΡΩΤΗΜΑ 1

Στο συγκεκριμένο ερώτημα ταξινομούμε κατά αύξουσα σειρά τις περιοχές, με βάση τις συνολικές τιμές των γεννήσεων με την χρήση των MergeSort και QuickSort αλγορίθμων. Οι μέθοδοι που καλούν τον κάθε sorting αλγόριθμο είναι οι merge & mergesort και quickSort αντίστοιχα και έχουν υλοποιηθεί με βάση τον ψευδοκώδικα που αναλύθηκε τόσο στις διαλέξεις όσο και στο βιβλίο του κ. Τσακαλίδη.

Κάνοντας run τον κώδικα μας , παρατηρούμε πως το sorting γίνεται πολύ πιο γρήγορα όταν χρησιμοποιούμε τον QuickSort παρά τον MergeSort. Παρατίθονται στιγμιότυπα από το runtime.

```
Choose sorting algorithm: 1 for MergeSort, 2 for QuickSort: 1
MergeSort: 1.4389 ms
      2013, Event Type: Births, Region: "Region not stated or area outside region"
             Event Type: Births, Region: "Region not stated or area outside region"
                                                                                                     Count:
                                     Region:
                                                                                                     Count:
                                               "Region not stated or area outside region
                                               "Region not stated or area out
                                                                                         ose sorting algorithm: 1 for MergeSort, 2 for QuickSort: 2
ickSort: 0.7934 ms
      2010,
                                     Region: "Region not stated or area out
             Event Type:
      2017
                           Births,
             Event Type: Births,
                                               West Coast region,
             Event Type: Births, Region: Tasman region, Count: 411
Event Type: Births, Region: West Coast region, Count: 417
                                  MergeSort: 1.4389 ms
```

QuickSort: 0.7934 ms

Γενικά, ο Mergesort όπως ήδη γνωρίζουμε έχει βέλτιστη ασυμπτωτική απόδοση στο χειρότερο σενάριο με πολυπλοκότητα O(nlogn). Αρχικά χωρίζει την είσοδο σε 2 ισομερή τμήματα, τα ταξινομεί και ύστερα τα συγχωνεύει με αναδρομική κλήση του αλγορίθμου. Οι συγκρίσεις στην χειρότερη περίπτωση που απαιτούνται για να γίνει συγχώνευση είναι n-1 ενώ για την ταξινόμηση μήκους n απαιτεί **το πολύ**  $n(logn) + 2^{logn} + 1$  συγκρίσεις.

Ο Quicksort από την άλλη, ανεξάρτητα από τις μεταθέσεις, απαιτεί n+1 συγκρίσεις με μέσο χρόνο συγκρίσεων O(nlogn) (όπως και ο Mergesort). Η διαφορά όμως μεταξύ Quicksort και Mergesort έγκειται στο γεγονός ότι ο Quicksort στο worst case scenario δεν έχει καλή απόδοση (πολυπλοκότητα  $O(n^2)$ ) ενώ ο Mergesort ακόμα και σε αυτό εγγυάται πως έχει T(n) = O(nlogn).

Δεν υπάρχει αντικειμενικά καλύτερος και χειρότερος αλγόριθμος. Όλα εξαρτώνται από το μέγεθος της εισόδου που θέλουμε να ταξινομήσουμε.

- Όταν το input είναι σχετικά μικρό, προτιμούμε τον Quicksort χάρη στην καλή cache απόδοση του.
- Όταν είναι μεγαλύτερο , επιλέγουμε τον Mergesort που εγγυάται πως ακόμα και στο worst case scenario θα έχει πολυπλοκότητα O(nlogn), πιο γρήγορη κατά πολύ από αυτή του Quicksort.

### ΕΡΩΤΗΜΑ 2

Σε αυτή την άσκηση ζητείται να ταξινομήσουμε κατά αύξουσα σειρά τις περιοχές, με βάση τις συνολικές τιμές των θανάτων αυτή την φορά, κάνοντας χρήση των HeapSort και CountingSort αλγορίθμων. Καθώς τρέχουμε τον κώδικα μας, παρατηρούμε πως το sorting γίνεται πολύ πιο γρήγορα όταν χρησιμοποιούμε τον CountingSort παρά τον HeapSort.

Από το runtime προκύπτει:

```
Exercise1
   Exercise3
  LExercise4
  Choose sorting algorithm: 1 for Heap Sort, 2 for Counting sort: 1
        2017
                    Type:
                          Deaths, Region:
                                           "Region not stated or area outside region"
        2019
              Event Type:
                                           "Region not stated or area outside region"
                                                                                          Count:
                     Type:
                           Deaths,
                                   Region:
                                            "Region not
                                                        stated or area outside region
                                            "Region not stated or area outside region"
                                                                                          Count
                    Type:
                                   Region:
                                           "Region not stated or area outside region
              Event
                     Type:
                           Deaths,
                                            "Region not stated or area outside region
                                   Region:
        2011
                                            "Region not stated or area outside region"
              Event
                     Type
                                   Region:
                                           "Region not stated or area outside region'
              Event
                     Type:
                           Deaths,
                                            "Region not stated or area outside region
                                            "Region not stated or area outside region
              Event
                                                                                          Count
                     Type:
                                   Region:
                                           "Region not stated or area outside region
                                                                                                 42
              Event
                     Type:
                           Deaths,
                                                        stated or area outside region
                                   Region:
                                            "Region not stated or area outside region"
                     Type:
              Event
                                                                                          Count
        2008
                                   Region:
                                           "Region not stated or area outside region"
                                                                                                 108
              Event
                           Deaths,
                                   Region:
                                            "Region not
                                                        stated or area outside region'
                     Type
                                            "Region not stated or area outside region"
                     Type:
                                   Region:
                                                                                          Count:
              Event
        2006
                                   Region:
                                            "Region not stated or area outside region"
                                   Region:
                     Type:
                                   Reaion:
                                           West Coast region.
              Event
        2010
                                   Region:
                           Deaths,
                                   Region:
                     Type
        2007
                                   Region:
              Event
                     Type:
                                                               Count:
        2009
                                   Region:
                                           West Coast region
                           Deaths,
                                   Region:
                     Type
        2008
                                   Region:
                                                 Coast regi
              Event
                     Type
        2020
              Event
                                   Region:
                           Deaths,
               Event
                                                 Coast
                     Type
                                                       regi
        2013
              Event
                                   Region:
                                   Region:
                    Type:
              Event Type:
                          Deaths, Region: West Coast regi
              Event Type: Deaths,
HeapSort: 0.9095 ms
CountingSort: 0.3123 ms
(σχεδόν <u>3x</u> τον χρόνο του CountingSort
χρειάστηκε ο HeapSort!)
```

O Countingsort από την άλλη είναι ένας αλγόριθμος που χρησιμοποιείται για την ταξινόμηση <u>integer</u> και μόνο αριθμών. O CountingSort μετράει πόσοι αριθμοί είναι μεγαλύτεροι από έναν δωσμένο αριθμό x για να μπορέσει να προσδιορίσει πού ακριβώς βρίσκεται το x μέσα στον πίνακα.

Το συνολικό του κόστος είναι O(n+k) όπου k το άνω φράγμα του διαστήματος [1,k]. Επομένως το αν ο καλύτερος αλγόριθμος για να χρησιμοποιήσουμε στην ταξινόμηση μας είναι ο Countingsort μάς το απαντάει η τιμή του k.

- Αν  $\kappa = O(n)$ , τότε T(n) = O(n+n) = O(2n) => T(n) = O(n) (ασυμπτωτικά βέλτιστος). Ομοίως αν έχω  $\kappa = O(nloglogn)$ .
  - Γενικά, αν το k είναι μικρός αριθμός (και ακέραιος), ο Countingsort είναι ακόμα καλύτερος από όλους τους άλλους αλγόριθμους σύγκρισης που έχουμε μάθει.
- Αν όμως  $k = O(n^2)$ , τότε ο αλγόριθμος απαιτεί μεγάλο χρόνο για να ταξινομήσει στοιχεία (άρα γίνεται πιο αργός και λιγότερο αποδοτικός για την δουλειά μας). Το ίδιο παρατηρούμε και όταν έχουμε ακόμα μεγαλύτερες τιμές για το k, όπως  $O(n^3)$ ,  $O(n^4)$  κοκ.

Όπως και στο ερώτημα 1 έτσι και εδώ η επιλογή του κατάλληλου αλγορίθμου πάλι εξαρτάται από το **μέγεθος και το είδος** της εισόδου που θέλουμε να ταξινομήσουμε.

- Αν έχουμε μέσα στα δεδομένα μας floats, chars κλπ (δεν μας νοιάζει αν το n είναι μεγάλο ή μικρό), προτιμότερο θα ήταν να διαλέξουμε τον Heapsort, καθώς θα είναι πιο γρήγορος σε κάθε πιθανό σενάριο συγκριτικά με τον Countingsort.
- Όταν όμως έχουμε ένα σύνολο n προς ταξινόμηση με n <<< k και μάλιστα τα n inputs είναι ακέραιοι αριθμοί , καλύτερα να επιλέξουμε τον Countingsort.

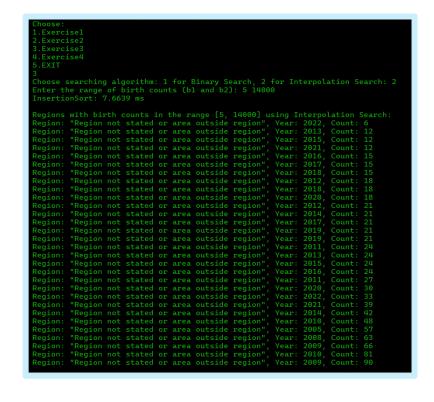
### ΕΡΩΤΗΜΑ 3

Στο εξης ερώτημα ταξινομούμε τις περιοχές με βάση τον αριθμό γεννήσεων , ο οποίος ανήκει σε ένα διάστημα τιμών [b1,b2], όπου b1,b2 ακέραιοι αριθμοί. Στο πρόγραμμα μας ζητείται από τον χρήστη να εισάγει τα δύο άκρα του διαστήματος με τους ακέραιους αριθμούς που επιθυμεί και πραγματοποιείται η αναζήτηση των περιοχών που έχουν γεννήσεις που ανήκουν στο διάστημα επιλογής.

Για την αναζήτηση χρησιμοποιούμε 2 μεθόδους, αυτή της **δυαδικής αναζήτησης** (binary search) και αυτή της **αναζήτησης** με παρεμβολή (interpolation search). Παρακάτω επισυνάπτονται στιγμιότυπα από το runtime της άσκησης:

```
Choose:
1.Exercise1
2.Exercise2
3.Exercise3
4.Exercise4
5.EXIT
3 Choose searching algorithm: 1 for Binary Search, 2 for Interpolation Search: 1 Enter the range of birth counts (b1 and b2): 5 14000
InsertionSort: 8.0261 ms

Regions with birth counts in the range [5, 14000] using Binary Search: Region: "Region not stated or area outside region", Year: 2022, Count: 6
Region: "Region not stated or area outside region", Year: 2013, Count: 12
Region: "Region not stated or area outside region", Year: 2013, Count: 12
Region: "Region not stated or area outside region", Year: 2014, Count: 12
Region: "Region not stated or area outside region", Year: 2017, Count: 12
Region: "Region not stated or area outside region", Year: 2017, Count: 15
Region: "Region not stated or area outside region", Year: 2018, Count: 15
Region: "Region not stated or area outside region", Year: 2018, Count: 15
Region: "Region not stated or area outside region", Year: 2018, Count: 18
Region: "Region not stated or area outside region", Year: 2018, Count: 18
Region: "Region not stated or area outside region", Year: 2018, Count: 18
Region: "Region not stated or area outside region", Year: 2012, Count: 18
Region: "Region not stated or area outside region", Year: 2014, Count: 21
Region: "Region not stated or area outside region", Year: 2014, Count: 21
Region: "Region not stated or area outside region", Year: 2014, Count: 21
Region: "Region not stated or area outside region", Year: 2019, Count: 21
Region: "Region not stated or area outside region", Year: 2019, Count: 21
Region: "Region not stated or area outside region", Year: 2019, Count: 21
Region: "Region not stated or area outside region", Year: 2019, Count: 24
Region: "Region not stated or area outside region", Year: 2011, Count: 24
Region: "Region not stated or area outside region", Year: 2011, Count: 24
Region: "Region not stated or area outside region", Year: 2016, Count: 30
Region: "Region not stated or area outside region", Year: 2016, Count: 30
Region: "Region not stated or area outside region",
```



Ας αναλύσουμε εκτενέστερα τις μεθόδους που χρησιμοποιήθηκαν παραπάνω.

Αρχικά, το **Binary Search** (δυαδική αναζήτηση) είναι μια μέθοδος «διαίρει και βασίλευε». Χρησιμοποιώντας while loop, χωρίζουμε το **sorted** array σε 2 κομμάτια και συγκρίνουμε συνεχώς με την δωσμένη τιμή μέχρι να την βρούμε ανάμεσα στα 2 άκρα αναζήτησης που εισήγαγε ο χρήστης. Η πολυπλοκότητα του Binary Search είναι O(logn) σε κάθε περίπτωση, τόσο στο average όσο και στο worst case scenario. Γενικά χαρακτηρίζεται ως ένας πολύ efficient τρόπος αναζήτησης, ακόμα και όταν το dataset είναι μεγάλο. Σημαντικό ωστόσο είναι πριν προχωρήσουμε στην δυαδική αναζήτηση να έχουμε κάνει sort το array από πριν (είτε σε αύξουσα είτε σε φθίνουσα σειρά), διότι ένα unsorted array προκαλεί προβλήματα και ανακριβή αποτελέσματα κατά την εκτέλεση του προγράμματος.

To **Interpolation Search** (αναζήτηση με παρεμβολή) από την άλλη βρίσκει προσεγγιστικά την θέση του στοιχείου που θέλουμε να αναζητήσουμε, κοιτώντας την ελάχιστη και μέγιστη τιμή του array.

Η αναζήτηση με παρεμβολή είναι προτιμότερη από την δυαδική αναζήτηση  $(O_{Interpolation}(loglogn))$ , όταν το **dataset είναι ομοιόμορφα κατανεμημένο**, διότι δεν χρειάζεται να κάνει όλες αυτές τις διαδοχικές διαιρέσεις του array για να βρει το key value και να χάσει αρκετό χρόνο (το παρατηρούμε και από τους χρόνους που αναγράφονται στα screenshots). Αν όμως το dataset **δεν είναι ομοιόμορφα κατανεμημένο**, τότε η αναζήτηση με παρεμβολή έχει χειρότερη επίδοση από ο,τι η δυαδική αναζήτηση, με πολυπλοκότητα στο worst case scenario  $O_{Interpolation}(n)$  έναντι του  $O_{BinSearch}(logn)$ .

(Προφανώς  $O_{BinSearch}(logn) \gg O_{Interpolation}(n)$ )

Συγκεντρωτικός πίνακας για το πότε χρησιμοποιώ την κάθε μέθοδο:

#### **Binary search**

- Όταν έχω ένα ομοιόμορφα κατανεμημένο και sorted dataset
- Όταν το dataset είναι στατικό και δεν αλλάζει.
- Όταν θέλω να έχω χαμηλή χρήση μνήμης.

### **Interpolation Search**

- Όταν έχω ένα μεγάλο, ομοιόμορφα κατανεμημένο και sorted dataset.
  - Όταν το dataset είναι μεταβαλλόμενο(dynamic).
- Όταν το dataset δεν είναι ομοιόμορφα κατανεμημένο αλλά εμφανίζει ομοιομορφία μέχρι έναν βαθμό.

### ΕΡΩΤΗΜΑ 4

Σε αυτό το ερώτημα υλοποιούμε ξανά το Ερώτημα 3 , αλλά αυτή την φορά χρησιμοποιούμε την Δυϊκή Αναζήτηση Παρεμβολής (**B**inary Interpolation **S**earch-**BIS**).

Ο μέσος χρόνος αναζήτησης του BIS είναι ο O(loglogn) ενώ στο worst case scenario αποκτά πολυπλοκότητα  $O(\sqrt{n})$ . Αυτό συμβαίνει, διότι στην πρώτη εκτέλεση του συμβαίνουν το πολύ  $\sqrt{n}$  συγκρίσεις, στην επόμενη εκτέλεση  $\sqrt{\sqrt{n}}$  κ.ο.κ. Δηλαδή προκύπτει η σχέση  $n^{\frac{1}{2}} + n^{\frac{1}{4}} + n^{\frac{1}{8}} + \cdots = O(\sqrt{n})$ 

Ο χρόνος χειρότερης περίπτωσης ωστόσο μπορεί να βελτιωθεί από  $O(\sqrt{n})$  σε O(logn), δίχως να χειροτερεύει ο χρόνος της μέσης περίπτωσης. Αυτό επιτυγχάνεται με την <u>εκθετική αύξηση</u> του i μέσα στο while loop, δηλαδή να έχουμε  $i\leftarrow 2*i$  αντί για  $i\leftarrow i+1$ . Έτσι, τα άλματα γίνονται ολοένα μεγαλύτερα, με το αριστερό άκρο να παραμένει διαρκώς σταθερό. Κατά συνέπεια, το τελευταίο υποδιάστημα είναι πολύ μεγαλύτερο από  $\sqrt{n}$  και μέσα σε αυτό εφαρμόζουμε δυική αναζήτηση στα στοιχεία (που ανήκουν σε αυτό) που απέχουν κατά  $\sqrt{n}$  και έτσι προκύπτει το ζητούμενο υποδιάστημα μεγέθους  $\sqrt{n}$ .

Ταυτόχρονα , $\alpha$ ν υποθέσουμε πως στο πρώτο βήμα εκτελούμε στην χειρότερη περίπτωση i συγκρίσεις , τότε :

$$2^{i}\sqrt{n} = n \Rightarrow 2^{i} = \sqrt{n} \Rightarrow i = \log(\sqrt{n})$$

Άρα, για το 1° βήμα χρειαζόμαστε χρόνο  $O(\log(\sqrt{n}))$ , για το 2° βήμα :  $log 2^{i-1} = O(i-1) = O(log i) = O(log(\sqrt{n}))$  κ.ο.κ Επομένως για κάθε επανάληψη του while loop , χρειάζεται O(log i) χρόνος στο worst case scenario.

Συνολικά δηλαδή θα χρειαστεί:

$$\log(\sqrt{n}) + \log\left(\sqrt{\sqrt{n}}\right) + \log\left(\sqrt{\sqrt{n}}\right) + \dots = \log n^{\frac{1}{2}} + \log n^{\frac{1}{4}} + \log n^{\frac{1}{8}} + \dots = \frac{1}{2}\log n + \frac{1}{4}\log n + \frac{1}{8}\log n + \dots$$

$$= \left(\frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \dots\right)\log n = O(\log n)$$

```
:kSort: 13.0899 ms
:or contents: 6 12 12 12 15 15 18 18 18 21 21 24 57 63 81 90 135 174 303 312 324 324 333 336 354 363 375 381 384 390 405 411 417 429 432 432 447 447 453
                                                                   Region: Marlborough region, Year: 2020, Count:
                                                                           Tasman region, Year: 2012,
Nelson region, Year: 2020,
                                                                                                            Count: 477
Count: 477
                                                                   Region:
                                                                   Region:
                                                                   Region: Marlborough region, Year:
                                                                   Region: Marlborough region, Year:
                                                                           Tasman region, Year: 2022
Nelson region, Year: 2022
                                                                   Region:
                                                                                                             Count: 483
                                                                   Region:
                                                                   Region: Marlborough region, Year:
                                                                                                            2014, Count:
                                                                   Region: Marlborough region, Year:
                                                                                                            2006,
                                                                           Marlborough region,
                                                                   Region: Tasman region, Year: 2013
                                                                                                            Count: 486
                                                                   Region: Marlborough region, Year:
                                                                   Region: Tasman region, Year:
                                                                   Region: Marlborough region, `
Region: Nelson region, Year:
                                                                                                                            495
                                                                                                     2021
                                                                                                             Count: 498
                                                                    legion: Tasman region, Year:
Παραπάνω, επιλέγουμε το διάστημα [6,663]
                                                                                                      2011
                                                                                                      2017
                                                                                                                     504
                                                                           Nelson region, Year:
                                                                    legion:
για αναζήτηση.
                                                                    legion: Marlborough region, Year:
                                                                                                            2013, Count:
                                                                    legion: Marlborough region,
                                                                                                                            504
Εκτυπώνονται οι περιοχές που επιβεβαιώνουν
                                                                   Region: Marlborough region,
Region: Tasman region, Year:
                                                                                                            2012, Count:
                                                                                                                            507
                                                                                                     2005
                                                                    legion: Marlborough region, Year:
                                                                                                            2007, Count:
το κριτήριο αναζήτησης.
                                                                   Region: Nelson region, Year: 2005
                                                                                                            Count: 519
                                                                                                      2006,
Ύστερα ζητάμε να εκτυπωθεί πού βρίσκεται
                                                                    legion: Marlborough region, Year: 2016, Count:
                                                                                                                            534
                                                                    Region: Nelson region, Year:
                                                                                                             Count: 534
                                                                   Region: Nelson region, Year:
Region: Nelson region, Year:
                                                                                                      2014,
2019,
μέσα στο array η τιμή 81. Η τιμή 81 βρίσκεται
                                                                    degion: Nelson region, Year:
                                                                                                             Count: 540
στην θέση 14.
                                                                    legion: Marlborough region, Year: 2011, Count:
                                                                                                                           540
                                                                                                            Count: 540
Count: 543
                                                                   Region: Nelson region, Year: 2016,
Region: Tasman region, Year: 2010,
                                                                    degion: Nelson region, Year:
                                                                                                      2012,
                                                                                                             Count:
                                                                                                                     546
                                                                    legion: Tasman region, Year:
                                                                                                      2006,
                                                                           Tasman region, Year:
Marlborough region,
                                                                    legion:
                                                                                                      2007
                                                                                                            2009, Count:
                                                                    legion:
                                                                    egion: Nelson region, Year:
                                                                                                     2013
                                                                                                             Count: 555
                                                                    legion: Tasman region, Year:
                                                                                                     2008,
                                                                    Region: Marlborough region,
                                                                                                            2008, Count:
                                                                    legion: Marlborough region,
                                                                    Region: Nelson region, Year:
                                                                                                      2011
                                                                                                             Count: 600
```

2009

2008

627

Count:

Region: Nelson region, Year:

1 was found in position 14

lumber to search: 81

egion: Nelson region, Year: egion: Nelson region, Year:

Region: Nelson region, Year: 2007,

Region: Gisborne region, Year: 2014, Count: 651 Region: Gisborne region, Year: 2020, Count: 663

# Συγκεντρωτικός κώδικας Μέρους Α΄

```
#include <iostream>
#include <fstream>
#include <vector>
#include <sstream>
#include <string>
#include <cmath>
#include <chrono>
using namespace std;
struct Data {
   int year;
   string eventType;
   string region;
   int count;
};
int stringToInt(const string& str) {
   int result;
   stringstream ss(str);
   ss >> result;
   return result;
}
class FileReader {
public:
    vector<Data> readDataFromFile(const string& filename) {
       vector<Data> data;
       ifstream file(filename);
        if (!file.is_open()) {
            cerr << "Failed to open the file." << endl;</pre>
            return data;
       }
        string line;
        while (getline(file, line)) {
            istringstream iss(line);
            string token;
            Data d;
            if (getline(iss, token, ','))
                d.year = stringToInt(token);
            if (getline(iss, token, ','))
                d.eventType = token;
            if (getline(iss, token, ','))
                d.region = token;
            if (getline(iss, token))
                d.count = stringToInt(token);
            data.push_back(d);
       }
        file.close();
        return data;
};
vector<Data> findDeaths(const vector<Data>& data) {
   vector<Data> deathRecords;
   for (const auto& entry : data) {
        if (entry.eventType == "Deaths") {
            deathRecords.push_back(entry);
       }
   }
   return deathRecords;
}
void printRecords(const vector<Data>& data) {
   for (const auto& d : data) {
```

```
cout << "Year: " << d.year << ", Event Type: " << d.eventType</pre>
            << ", Region: " << d.region << ", Count: " << d.count << endl;</pre>
   }
}
void countingSort(vector<Data>& A, vector<Data>& B, int k) {
    auto start = chrono::steady_clock::now();
    vector<int> C(k + 1, 0);
    for (int j = 0; j < A.size(); ++j)
        C[A[j].count]++;
    for (int i = 1; i <= k; ++i)
        C[i] += C[i - 1];
    for (int j = A.size() - 1; j >= 0; --j) {
        B[C[A[j].count] - 1] = A[j];
        C[A[j].count]--;
    }
    auto end = chrono::steady_clock::now();
    auto diff = end - start;
    cout << "CountingSort: " << chrono::duration <double, milli>(diff).count() << " ms" << endl;</pre>
}
void merge(vector<Data>& arr, int left, int mid, int right) {
    int n1 = mid - left + 1;
    int n2 = right - mid;
    vector<Data> L(n1);
    vector<Data> R(n2);
    for (int i = 0; i < n1; ++i)
        L[i] = arr[left + i];
    for (int j = 0; j < n2; ++j)
        R[j] = arr[mid + 1 + j];
    int i = 0, j = 0, k = left;
    while (i < n1 \&\& j < n2) {
        if (L[i].count <= R[j].count) {</pre>
            arr[k] = L[i];
            ++i;
        }
        else {
            arr[k] = R[j];
            ++j;
        }
        ++k;
    }
    while (i < n1) {
        arr[k] = L[i];
        ++i;
        ++k;
    }
    while (j < n2) {
        arr[k] = R[j];
        ++j;
        ++k;
    }
}
void mergeSort(vector<Data>& arr, int left, int right) {
    if (left < right) {</pre>
        auto start = chrono::steady_clock::now();
        int mid = left + (right - left) / 2;
        mergeSort(arr, left, mid);
        mergeSort(arr, mid + 1, right);
        merge(arr, left, mid, right);
        if (left == 0 && right == arr.size() - 1) { // Check if it's the outermost call
```

```
auto end = chrono::steady_clock::now();
            auto diff = end - start;
    cout << "MergeSort: " << chrono::duration <double, milli>(diff).count() << " ms" << endl;</pre>
        }
    }
}
int partition(vector<Data>& arr, int low, int high) {
    int pivot = arr[high].count;
    int i = low - 1;
    for (int j = low; j <= high - 1; j++) {
        if (arr[j].count < pivot) {</pre>
            i++;
            swap(arr[i], arr[j]);
        }
    }
    swap(arr[i + 1], arr[high]);
    return i + 1;
}
void quickSort(vector<Data>& arr, int low, int high) {
    if (low < high) {</pre>
        auto start = chrono::steady_clock::now();
        int pi = partition(arr, low, high);
        quickSort(arr, low, pi - 1);
        quickSort(arr, pi + 1, high);
        if (low == 0 && high == arr.size() - 1) { // Check if it's the outermost call
            auto end = chrono::steady_clock::now();
            auto diff = end - start;
            cout << "QuickSort: " << chrono::duration <double, milli>(diff).count() << " ms" << endl;</pre>
        }
    }
}
void heapify(vector<Data>& arr, int n, int i) {
    int largest = i;
    int left = 2 * i + 1;
    int right = 2 * i + 2;
    if (left < n && arr[left].count > arr[largest].count)
        largest = left;
    if (right < n && arr[right].count > arr[largest].count)
        largest = right;
    if (largest != i) {
        swap(arr[i], arr[largest]);
        heapify(arr, n, largest);
    }
}
void heapSort(vector<Data>& arr) {
    auto start = chrono::steady_clock::now();
    int n = arr.size();
    for (int i = n / 2 - 1; i >= 0; i--)
        heapify(arr, n, i);
    for (int i = n - 1; i > 0; i--) {
        swap(arr[0], arr[i]);
        heapify(arr, i, 0);
    }
    auto end = chrono::steady_clock::now();
    auto diff = end - start;
    cout << "HeapSort: " << chrono::duration <double, milli>(diff).count() << " ms" << endl;</pre>
}
class BinarySearchRegionSearcher {
```

```
vector<Data> searchRegions(const vector<Data>& data, int b1, int b2) {
        vector<Data> sortedData = data;
        insertionSort(sortedData);
        auto leftIt = binarySearch(sortedData, b1);
        vector<Data> result;
        for (auto it = leftIt; it != sortedData.end() && it->count <= b2; ++it) {</pre>
            result.push_back(*it);
        }
        return result;
    }
private:
void insertionSort(vector<Data>& data) {
    auto start = chrono::steady_clock::now();
    for (size_t i = 1; i < data.size(); ++i) {</pre>
        Data key = data[i];
        int j = i - 1;
        while (j >= 0 && data[j].count > key.count) {
            data[j + 1] = data[j];
            j = j - 1;
        data[j + 1] = key;
    }
    auto end = chrono::steady_clock::now();
    auto diff = end - start;
    cout << "InsertionSort: " << chrono::duration <double, milli>(diff).count() << " ms" << endl;</pre>
}
    vector<Data>::iterator binarySearch(vector<Data>& data, int key) {
        int low = 0;
        int high = data.size() - 1;
        while (low <= high) {</pre>
            int mid = low + (high - low) / 2;
            if (data[mid].count == key)
                return data.begin() + mid;
            else if (data[mid].count < key)</pre>
                low = mid + 1;
            else
                high = mid - 1;
        }
        return data.begin() + low;
    }
};
class InterpolationSearchRegionSearcher {
public:
    vector<Data> searchRegions(const vector<Data>& data, int b1, int b2) {
        vector<Data> sortedData = data;
        insertionSort(sortedData);
        auto leftIt = interpolationSearch(sortedData, b1);
        vector<Data> result;
        for (auto it = leftIt; it != sortedData.end() && it->count <= b2; ++it) {</pre>
            result.push_back(*it);
        }
        return result;
    }
private:
void insertionSort(vector<Data>& data) {
    auto start = chrono::steady_clock::now();
```

```
for (size_t i = 1; i < data.size(); ++i) {</pre>
       Data key = data[i];
       int j = i - 1;
       while (j >= 0 && data[j].count > key.count) {
           data[j + 1] = data[j];
           j = j - 1;
       }
       data[j + 1] = key;
   }
   auto end = chrono::steady_clock::now();
   auto diff = end - start;
   cout << "InsertionSort: " << chrono::duration <double, milli>(diff).count() << " ms" << endl;</pre>
}
   vector<Data>::iterator interpolationSearch(vector<Data>& data, int key) {
       int low = 0;
       int high = data.size() - 1;
       while (low <= high && key >= data[low].count && key <= data[high].count) {</pre>
           int pos = low + ((key - data[low].count) * (high - low)) / (data[high].count - data[low].count);
           if (data[pos].count == key) {
               return data.begin() + pos;
           }
           else if (data[pos].count < key) {</pre>
               low = pos + 1;
           }
           else {
               high = pos - 1;
           }
       }
       return data.begin() + low;
   }
};
void readDataforask4(const string& filename, vector<Data>& data) {
   ifstream file(filename);
   if (!file.is_open()) {
       cerr << "Error: Unable to open file: " << filename << endl;</pre>
       return;
   }
   string line;
   while (getline(file, line)) {
       stringstream ss(line);
       string token;
       getline(ss, token, ',');
       int year = stoi(token);
       getline(ss, token, ',');
       string eventType = token;
       getline(ss, token, ',');
       string region = token;
       getline(ss, token, ',');
       int count = stoi(token);
       if (eventType == "Births") {
           Data d = { year, eventType, region, count };
           data.push_back(d);
       }
   }
   file.close();
}
int access(int x, vector<Data>& S, int start, int end,int flag) {
   int left = start;
   int right = end;
   if (x < S[left].count || x > S[right].count) {
       cout << x << " was not found." << endl;</pre>
```

```
return -1;
    }
    int size = right - left + 1;
    int next = left + ((size * (x - S[left].count)) / (S[right].count - S[left].count));
    //removed +1 was causing problems;
    while (left <= right) {</pre>
         size = right - left + 1;
         if (size <= 3) {
             for (int j = left; j <= right; j++) {</pre>
                  if (S[j].count == x) {
                      cout << x << " was found in position " << j << endl;</pre>
                      return j;
                  }
             cout << x << " was not found." << endl;</pre>
             return -1;
        }
         if (x == S[next].count) {
             if (flag = 0) {
                  cout << x << " was found in position " << next << endl;</pre>
                  return next;
             }
             else {
                  return next;
             }
         }
         int i = 0;
         int jump = sqrt(size);
         if (x > S[next].count) {
             while (next + i * jump <= right && x > S[next + i * jump].count) {
             }
             left = next + (i - 1) * jump + 1;
             right = min(next + i * jump, end);
        }
         else {
             while (next - i * jump >= left && x < S[next - i * jump].count) {</pre>
                 i++;
             right = next - (i - 1) * jump - 1;
             left = max(next - i * jump, start);
        }
         if (left <= right) {</pre>
             next = left + ((right - left) * (x - S[left].count)) / (S[right].count - S[left].count);
        }
         else {
             break;
         }
    }
    \mathsf{cout} \ \mathrel{<<} \ \mathsf{x} \ \mathrel{<<} \ \mathsf{"} \ \mathsf{was} \ \mathsf{not} \ \mathsf{found."} \ \mathrel{<<} \ \mathsf{endl};
    return -1;
void printVectorInRange(const vector<Data>& S, int start, int end) {
    cout << "\nRegions with birth counts in the range [" << start << ", " << end << "]\n";</pre>
    for (int i = start; i <= end; ++i) {</pre>
          cout << "Region: " << S[i].region << ", Year: " << S[i].year << ", Count: "</pre>
             << S[i].count << endl;</pre>
    }
void printVector(const vector<Data>& vec) {
    cout << "Vector contents:";</pre>
    for (int i = 0; i < vec.size(); ++i) {</pre>
        cout << " " << vec[i].count;</pre>
    }
    cout << endl;</pre>
```

}

}

```
}
int main() {
   FileReader reader;
    vector<Data> data = reader.readDataFromFile("data.txt");
    vector<Data> data2;
    readDataforask4("data.txt", data2);
    int choice, startIndex, endIndex, elementIndex;
    int start, end;
    int element;
    do {
         cout << "Choose:\n"</pre>
            "1.Exercise1\n"
            "2.Exercise2\n"
            "3.Exercise3\n"
            "4.Exercise4\n"
            "5.EXIT\n";
         cin >> choice;
        switch (choice) {
        case 1: {
            int sortingChoice;
            cout << "Choose sorting algorithm: 1 for MergeSort, 2 for QuickSort: ";</pre>
            cin >> sortingChoice;
            vector<Data> data_births;
            for (const auto& elements : data) {
                if (elements.eventType == "Births") {
                    data_births.push_back(elements);
                }
            }
            int n = data_births.size();
            if (sortingChoice == 1) {
                mergeSort(data_births, 0, n - 1);
                cout << "\nSorted by MergeSort:\n";</pre>
            }
            else if (sortingChoice == 2) {
                quickSort(data_births, 0, n - 1);
                 cout << "\nSorted by QuickSort:\n";</pre>
            }
            else {
                 cout << "Invalid choice. Exiting." << endl;</pre>
                return 1;
            printRecords(data_births);
            break;
        }
        case 2: {
            int sortingChoice;
             cout << "Choose sorting algorithm: 1 for Heap Sort, 2 for Counting sort: ";</pre>
             cin >> sortingChoice;
             vector<Data> data_deaths;
            for (const auto& elements : data) {
                if (elements.eventType == "Deaths") {
                    data_deaths.push_back(elements);
                }
            }
            if (sortingChoice == 1) {
                heapSort(data_deaths);
                 cout << "\nSorted by Heap:\n";</pre>
            }
            else if (sortingChoice == 2) {
                int maxCount = 0;
                for (const auto& d : data_deaths) {
                    if (d.count > maxCount) maxCount = d.count;
                }
```

vector<Data> sortedDeaths(data\_deaths.size());

```
countingSort(data_deaths, sortedDeaths, maxCount);
                 data_deaths = sortedDeaths;
                 cout << "\nSorted by Counting:\n";</pre>
            }
            else {
                 cout << "Invalid choice. Exiting." << endl;</pre>
                return 1;
            }
            printRecords(data_deaths);
            break;
        }
        case 3: {
            int searchChoice;
             cout << "Choose searching algorithm: 1 for Binary Search, 2 for Interpolation Search: ";</pre>
             cin >> searchChoice;
            int b1, b2;
             cout << "Enter the range of birth counts (b1 and b2): ";</pre>
             cin >> b1 >> b2;
            switch (searchChoice) {
            case 1: {
                BinarySearchRegionSearcher binarySearcher;
                 vector<Data> regionsBinary = binarySearcher.searchRegions(data, b1, b2);
                 cout << "\nRegions with birth counts in the range [" << b1 << ", " << b2</pre>
                     << "] using Binary Search:\n";</pre>
                for (const auto& region : regionsBinary) {
                      cout << "Region: " << region.region << ", Year: " << region.year << ", Count: "</pre>
                         << region.count << endl;</pre>
                 }
                break;
            }
            case 2: {
                InterpolationSearchRegionSearcher interpolationSearcher;
                 vector<Data> regionsInterpolation = interpolationSearcher.searchRegions(data, b1, b2);
                 cout << "\nRegions with birth counts in the range [" << b1 << ", " << b2</pre>
                     << "] using Interpolation Search:\n";</pre>
                for (const auto& region : regionsInterpolation) {
                      cout << "Region: " << region.region << ", Year: " << region.year << ", Count: "</pre>
                         << region.count << endl;</pre>
                }
                break;
            }
            default:
                 cout << "Invalid choice. Exiting." << endl;</pre>
                return 1;
            }
            break;
        }
        case 4:
            while (true) {
                quickSort(data2, 0, data2.size() - 1);
                printVector(data2);
                cout << "Please give the start and end of the space you want to search in (values must be part of</pre>
the vector):" << endl;</pre>
                cin >> start >> end;
                 startIndex = access(start, data2, 0, data2.size() - 1,0);
                endIndex = access(end,data2, 0, data2.size() - 1,0);
                if (startIndex != -1 && endIndex != -1) {
                     printVectorInRange(data2, startIndex, endIndex);
                }
                else {
```

```
cout << "Invalid start or end. Please try again." << endl;</pre>
                }
            }
            cout << "Number to search: ";</pre>
            cin >> element;
            elementIndex = access(element, data2, 0, data2.size() - 1,1);
            startIndex = access(start, data2, 0, data2.size() - 1,1);
            endIndex = access(end,data2, 0, data2.size() - 1,1);
            if (elementIndex < startIndex || elementIndex > endIndex) {
                cout << element << " was not found." << endl;</pre>
            }
            else {
               access(element, data2, startIndex, endIndex,0);
            }
            break;
        case 5:
            cout << "Exiting...";</pre>
             cout << "Invalid choice. Exiting." << endl;</pre>
            return 1;
        }
    }while ( choice != 5);
    return 0;
}
```

#### PART II - BSTs && HASHING

### ΕΡΩΤΗΜΑ Α

Σε αυτό το ερώτημα μας ζητείται να δημιουργήσουμε ένα Δυαδικό Δένδρο Αναζήτησης (ΔΔΑ) στο οποίο κάθε κόμβος του διατηρεί την εγγραφή (Region, Period, Count\_of\_Births), ύστερα διατάσσεται ως προς το πεδίο Region και υλοποιείται με δυναμική διαχείριση μνήμης.

Αρχικά , το **Δυαδικό Δένδρο Αναζήτησης** είναι μια δομή δεδομένων που αποτελείται από κόμβους και έχει τα παρακάτω χαρακτηριστικά:

- 1. Κάθε δέντρο έχει στην κορυφή έναν κόμβο ρίζας.
- 2. Ο ριζικός κόμβος έχει μηδέν, έναν ή δύο θυγατρικούς κόμβους.
- 3. Κάθε θυγατρικός κόμβος έχει μηδέν, έναν ή δύο θυγατρικούς κόμβους.
- 4. Κάθε κόμβος το πολύ δύο παιδιά.
- 5. Για κάθε κόμβο, οι αριστεροί απόγονοί του είναι μικρότεροι από τον τρέχοντα κόμβο, ο οποίος είναι μικρότερος από τους δεξιούς απόγονους.

Το AVL (Adelson-Velskii-Landis) δέντρο είναι ένα δυαδικό ισοζυγισμένο δέντρο με την διαφορά ότι: για κάθε κόμβο του ισχύει ότι τα ύψη των υποδέντρων του διαφέρουν το πολύ κατά ένα (συντελεστής ισορροπίας). Έστω δηλαδή εσωτερικός κόμβος u και L(u), R(u) τα υποδέντρα με ρίζες το αριστερό και δεξί παιδί του u αντίστοιχα. Σε κάθε u ορίζουμε την ποσότητα που ονομάζεται ισοζύγιση του u (συμβολίζεται με hb(u)) και δίνεται από την σχέση:

$$hb(u) = \Upsilon \psi o \varsigma(R(u)) - \Upsilon \psi o \varsigma(L(u))$$

1.Screenshots από την απεικόνιση του ΔΔΑ με ενδο-διατεταγμένη διάσχιση. Κάθε απεικόνιση περιέχει μια επικεφαλίδα με τον τίτλο της περιοχής της εγγραφής που απεικονίζεται

```
Search for birth population given region and year
Modify birth population given region and year
                    "Region not stated or area outside region"
                     "Region not stated or area outside region 
"Region not stated or area outside region
                     "Region not stated or area outside region
"Region not stated or area outside region
                     "Region not stated or area outside region
                     "Region not stated or area outside region
"Region not stated or area outside region
                     "Region not stated or area outside
                      Region not stated or area outside region
                      "Region not stated or area outside region
"Region not stated or area outside region
                      'Region not stated or area outside region
    Births, "Region not stated or area outside region",
Births, "Region not stated or area outside region",
Births, "Region not stated or area outside region"
                    "Region not stated or area outside region",
"Region not stated or area outside region"
                    "Region not stated or area outside region"
                    "Region not stated or area outside region"
"Region not stated or area outside region"
"Region not stated or area outside region"
                   "Region not stated or area outside region",
"Region not stated or area outside region"
    Deaths, "Region not stated or area outside region",
Deaths, "Region not stated or area outside region",
Deaths, "Region not stated or area outside region",
                    "Region not stated or area outside region"
"Region not stated or area outside region"
    Deaths, "Region not stated or area outside region",
Deaths, "Region not stated or area outside region",
Deaths, "Region not stated or area outside region",
```

```
2017, Deaths, Auckland region, 8577
2018, Deaths, Auckland region, 8586
2018, Deaths, Auckland region, 8586
2019, Deaths, Auckland region, 8619
2019, Deaths, Auckland region, 8619
2020, Deaths, Auckland region, 8328
2020, Deaths, Auckland region, 8907
2021, Deaths, Auckland region, 8907
2021, Deaths, Auckland region, 9783
2022, Deaths, Bay of Plenty region, 3771
2005, Births, Bay of Plenty region, 3771
2006, Births, Bay of Plenty region, 3840
2007, Births, Bay of Plenty region, 3840
2007, Births, Bay of Plenty region, 4053
2007, Births, Bay of Plenty region, 4053
2007, Births, Bay of Plenty region, 4053
2008, Births, Bay of Plenty region, 4053
2009, Births, Bay of Plenty region, 3939
2009, Births, Bay of Plenty region, 3939
2009, Births, Bay of Plenty region, 3939
2010, Births, Bay of Plenty region, 3957
2010, Births, Bay of Plenty region, 3957
2011, Births, Bay of Plenty region, 3951
2012, Births, Bay of Plenty region, 3951
2013, Births, Bay of Plenty region, 3951
2014, Births, Bay of Plenty region, 3876
2013, Births, Bay of Plenty region, 3876
2014, Births, Bay of Plenty region, 3876
2015, Births, Bay of Plenty region, 3876
2016, Births, Bay of Plenty region, 3879
2017, Births, Bay of Plenty region, 3879
2018, Births, Bay of Plenty region, 3899
2019, Births, Bay of Plenty region, 3899
2014, Births, Bay of Plenty region, 3899
2014, Births, Bay of Plenty region, 3899
2015, Births, Bay of Plenty region, 3899
2016, Births, Bay of Plenty region, 3899
2017, Births, Bay of Plenty region, 3899
2018, Births, Bay of Plenty region, 3899
2019, Births, Bay of Plenty region, 2012
2011, Births, Bay of Plenty region, 2021
2012, Births, Bay of Plenty region, 2021
2022, Births, Bay of Plenty region, 2139
2023, Deaths, Bay of
```

### 2.Αναζήτηση του αριθμού γεννήσεων για συγκεκριμένη χρονική περίοδο και περιοχή που δίνονται από το χρήστη.

Αναζητούμε την περιοχή West Coast το 2022 και μας εμφανίζει 303 γεννήσεις.

```
What would you like to do?

1. Organise by Births
2. Organise by region
3.Use hashing to search, insert or delete
4. Exit
2

What would you like to do?
1. Show AVL tree in order
2. Search for birth population given region and year
3. Modify birth population given region and year
4. Delete a region
5. Exit
2
Enter the region you want to find: West Coast region Enter the year you want to find: 2022

Node found: 2022, Births, West Coast region, 303
```

Εδώ αναζητούμε μία άλλη εγγραφή με όνομα Australia , την χρονιά 2024 και αφού δεν υπάρχει κάπου τότε εμφανίζεται το παρακάτω μήνυμα:

```
What would you like to do?

1. Show AVL tree in order

2. Search for birth population given region and year

3. Modify birth population given region and year

4. Delete a region

5. Exit

2
Enter the region you want to find: Australia
Enter the year you want to find: 2024

Node with region Australia and year 2024 for Births not found.
```

3. Τροποποίηση του πεδίου αριθμού γεννήσεων για συγκεκριμένη χρονική περίοδο και περιοχή που δίνονται από το χρήστη

```
What would you like to do?

1. Show AVL tree in order

2. Search for birth population given region and year

3. Modify birth population given region and year

4. Delete a region

5. Exit

3

Enter the region you want to modify population for:

West Coast region

Enter the year: 2020

Enter the new population: 541

Population for region West Coast region in year 2020 updated to 541

What would you like to do?

1. Show AVL tree in order

2. Search for birth population given region and year

3. Modify birth population given region and year

4. Delete a region

5. Exit

1

In Order Traversal of the created AVL Tree is:

REGION: "Region not stated or area outside region", 57

2006, Births, "Region not stated or area outside region", 174

2008, Births, "Region not stated or area outside region", 174

2008, Births, "Region not stated or area outside region", 63

2009, Births, "Region not stated or area outside region", 63

2009, Births, "Region not stated or area outside region", 174

2011, Births, "Region not stated or area outside region", 81

2011, Births, "Region not stated or area outside region", 12

2016, Births, "Region not stated or area outside region", 12

2017, Births, "Region not stated or area outside region", 12

2018, Births, "Region not stated or area outside region", 12

2019, Births, "Region not stated or area outside region", 12

2011, Births, "Region not stated or area outside region", 12

2012, Births, "Region not stated or area outside region", 12

2013, Births, "Region not stated or area outside region", 12

2016, Births, "Region not stated or area outside region", 12

2017, Births, "Region not stated or area outside region", 12

2018, Births, "Region not stated or area outside region", 12

2019, Births, "Region not stated or area outside region", 12

2010, Births, "Region not stated or area outside region", 13

2011, Births, "Region not stated or area outside region", 13

2017, Births, "Region not stated or area outside region", 13

2018, Births, "Region not stated or area outside region", 13
```

```
Births, West Coast region,
     Births, West Coast region, 453
2009
     Births, West Coast region, 429
2010
     Births, West Coast region, 432
     Births, West Coast region, 417
2012
2013
     Births, West Coast region,
                                 384
2014
     Births, West Coast region, 381
2016.
2017
             West Coast region,
     Births,
              West Coast region,
     Births, West Coast region,
     Deaths, West Coast region,
     Deaths, West Coast region, 273
2009
     Deaths, West Coast region, 264
2010
     Deaths, West Coast region, 249
      Deaths, West Coast region, 291
     Deaths, West Coast region, 252
2012,
2013
     Deaths, West Coast region, 291
     Deaths, West Coast region,
     Deaths, West Coast region, 294
2016
2017
     Deaths, West Coast region,
     Deaths, West Coast region, 273
     Deaths, West Coast region, 336
     Deaths, West Coast region,
```

<u>Αλλαγή των γεννήσεων για την περιοχή West Coast το 2020 σε 541</u>

4. Διαγραφή μιας εγγραφής βάσει της περιοχής που δίνεται από τον χρήστη.

```
What would you like to do?

1. Show AVL tree in order

2. Search for birth population given region and year

3. Modify birth population given region and year

4. Delete a region

5. Exit

4

Give region to delete:

West Coast region
```

Επιλέγουμε να διαγράψουμε τις εγγραφές που αφορούν την περιοχή

West Coast και εκτυπώνουμε πάλι τις περιοχές ταξινομημένες.

Βλέπουμε πως πράγματι έχει διαγραφεί η West Coast.

```
2006, Deaths, Tasman region, 342
2007, Deaths, Tasman region, 324
2008, Deaths, Tasman region, 390
2010, Deaths, Tasman region, 300
2011, Deaths, Tasman region, 348
2012, Deaths, Tasman region, 348
2012, Deaths, Tasman region, 372
2014, Deaths, Tasman region, 372
2014, Deaths, Tasman region, 375
2016, Deaths, Tasman region, 375
2016, Deaths, Tasman region, 375
2016, Deaths, Tasman region, 372
2018, Deaths, Tasman region, 372
2018, Deaths, Tasman region, 372
2019, Deaths, Tasman region, 450
2020, Deaths, Tasman region, 450
2021, Deaths, Tasman region, 460
2021, Deaths, Tasman region, 460
2022, Deaths, Tasman region, 460
2021, Deaths, Tasman region, 460
2022, Deaths, Tasman region, 667
2006, Births, Waikato region, 5667
2006, Births, Waikato region, 6231
2008, Births, Waikato region, 6231
2008, Births, Waikato region, 6423
2009, Births, Waikato region, 6423
2009, Births, Waikato region, 6324
2011, Births, Waikato region, 6914
2012, Births, Waikato region, 6951
2013, Births, Waikato region, 6681
2014, Births, Waikato region, 6234
2016, Births, Waikato region, 6234
2016, Births, Waikato region, 624
2017, Births, Waikato region, 6204
2018, Births, Waikato region, 6204
2019, Births, Waikato region, 6204
2019, Births, Waikato region, 627
2020, Births, Waikato region, 627
2020, Births, Waikato region, 627
2021, Births, Waikato region, 6387
2022, Births, Waikato region, 2754
2007, Deaths, Waikato region, 2772
2011, Deaths, Waikato region, 2772
2011, Deaths, Waikato region, 2772
2011, Deaths, Waikato region, 2919
2014, Deaths, Waikato region, 3066
2017, Deaths, Waikato region, 3066
2017, Deaths, Waikato region, 307
2021, Deaths, Waikato region, 3393
2022, Deaths, Waikato region, 3393
2022, Deaths, Waikato region, 3378
2013, Deaths, Waikato region, 3393
2024, Deaths, Waikato region, 3393
2025, Deaths, Waikato region, 3393
2026, Deaths, Waikato region, 3393
2027, Deaths, Waikato region, 3393
2029, Deaths, Waikato region, 3393
2020, Deaths, Waikato region, 3066
2017, Beaths, Waikato region, 3393
2020, Deaths, Waikato region
```

### ΕΡΩΤΗΜΑ Β

Σε αυτό το ερώτημα τροποποιήσαμε κατάλληλα τον κώδικα του (A), ώστε το αρχείο να διαβάζεται στο ΔΔΑ με βάση τον αριθμό γεννήσεων (Count\_of\_Births, Period, Region). Το ΔΔΑ διατάσσεται ως προς το πεδίο  $Count_of_Births$  και υλοποιείται με δυναμική διαχείριση μνήμης.

Παρακάτω υπάρχει στιγμιότυπο που εμφανίζει το μενού με τις επιλογές:

- 1. Εύρεση Περιοχής/Περιοχών με τον μέγιστο αριθμό γεννήσεων.
- 2. Εύρεση Περιοχής/Περιοχών με τον ελάχιστο αριθμό γεννήσεων.

```
What would you like to do?

1. Organise by Births
2. Organise by region
3.Use hashing to search, insert or delete
4. Exit

1

What would you like to do?
1. Show most Births
2. Show least Births
3. Show AVL tree in order
4. Exit

1

Node with maximum population: 2008, Births, New Zealand, 64344
What would you like to do?
1. Show most Births
2. Show least Births
3. Show AVL tree in order
4. Exit
2

Node with minimum population: 2022, Births, "Region not stated or area outside region", 6
What would you like to do?
1. Show most Births
2. Show least Births
3. Show AVL tree in order
4. Exit
2

Node with minimum population: 2022, Births, "Region not stated or area outside region", 6
What would you like to do?
1. Show most Births
2. Show least Births
3. Show AVL tree in order
4. Exit
```

### ΕΡΩΤΗΜΑ Γ

Στο τελευταίο ερώτημα, υλοποιήσαμε πάλι το ερώτημα (A) κάνοντας χρήση hashing με αλυσίδες αυτή την φορά αντί για  $\Delta\Delta$ A. Σύμφωνα με την εκφώνηση, η συνάρτηση κατακερματισμού υπολογίζεται ως το υπόλοιπο (modulo) της διαίρεσης του αθροίσματος των κωδικών ASCII των επιμέρους χαρακτήρων που απαρτίζουν την ΠΕΡΙΟΧΗ (Region) με ένα περιττό αριθμό m που συμβολίζει το πλήθος των κάδων (buckets).

Π.χ. για ΠΕΡΙΟΧΗ="Northland region" και m=11, ισχύει:

```
Hash("Northland\ region") = [ASCII('N') + ASCII('o') + ASCII('r') + ... ... + ASCII('i') + ASCII('o') + ASCII('n')]\ mod\ 11.
```

Παρακάτω επισυνάπτονται screenshots από το runtime της εφαρμογής

1.Αναζήτηση του αριθμού γεννήσεων για συγκεκριμένη χρονική περίοδο και περιοχή που δίνονται από το χρήστη.

Αναζητούμε το West Coast region,2022 (εμφανίζει 303 births) και το West Coast region, 2024 (δεν υπάρχει η εγγραφή και δεν βρίσκει κάτι)

```
What would you like to do ?
1. Organise by Births
Organise by region
3.Use hashing to search, insert or delete
4. Exit
                                                     Remove an entry

    Search for an event

                                                   Enter the place you want to find: West Coast region
                                                   Enter the date you want to find: 2024
Remove an entry
3. Change amount for an event
                                                   Place West Coast region and date 2024 was not found or was all Deaths
4. Exit
Enter your choice: 1
Enter the place you want to find: West Coast region
Enter the date you want to find: 2022
 found: 2022, Births, West Coast region, 303
```

2. Τροποποίηση του πεδίου αριθμού γεννήσεων για συγκεκριμένη χρονική περίοδο και περιοχή που δίνονται από τον χρήστη.

```
Menu:
1. Search for an event
2. Remove an entry
3. Change amount for an event
4. Exit
Enter your choice: 3
Enter the place: Auckland region
Enter the date: 2020
Please enter new number below:
58
Menu:
1. Search for an event
2. Remove an entry
3. Change amount for an event
4. Exit
Enter your choice: 1
Enter the place you want to find: Auckland region
Enter the date you want to find: 2020
 found: 2020, Births, Auckland region, 58
Menu:
1. Search for an event
2. Remove an entry
3. Change amount for an event
4. Exit
Enter your choice: 4
Exiting program.
What would you like to do ?
1. Organise by Births
2. Organise by region
3.Use hashing to search, insert or delete
4. Exit
Exiting programm...
Process returned 0 (0x0) execution time : 230.356 s
Press any key to continue.
```

3. Διαγραφή μιας εγγραφής βάσει της περιοχής που δίνεται από τον χρήστη

```
Menu:
1. Search for an event
2. Remove an entry
3. Change amount for an event
4. Exit
Enter your choice: 2
Enter the place to remove: West Coast region
West Coast region
Entry removed.
```

# Συγκρεντρωτικός κώδικας Μέρους Β'

```
#include <iostream>
#include <fstream>
#include <string>
#include <sstream>
#include <vector>
#include <list>
using namespace std;
struct info {
   int date;
   string type;
   string place;
   int amount;
};
int stringToIntH(const string& str) {
   int result;
   stringstream ss(str);
   ss >> result;
   return result;
}
// Define the HashTable class
class HashTable {
private:
   int size;
   vector<list<info>> table;
   // Hash function to determine index
   int hash(const string& key) {
       size = key.size();
       int hashValue = 0;
       for (char c : key) {
           hashValue += c;
       }
       return hashValue % size;
   }
public:
   // Constructor
   HashTable(int size) : size(size), table(size) {}
   // Insertion method
   void insert(const info& data) {
       int index = hash(data.place);
       table[index].push_back(data);
   }
   // Search method
   info* searchHASH(string place, int date, string event) {
       int index = hash(place);
       for (auto& element : table[index]) {
           if (element.place == place && element.date == date && element.type == event) {
               return &element;
           }
       }
       return NULL;
   }
   // Deletion method
   void remove(const string& region) {
       int index = hash(region);
       for (auto it = table[index].begin(); it != table[index].end();) {
           if (it->place == region) {
               it = table[index].erase(it);
           else {
               it++;
```

```
}
    }
    info* change_amount(string place, int date, string event) {
        int index = hash(place);
        int num;
        for (auto& element : table[index]) {
            if (element.place == place && element.date == date && element.type == event) {
                cout << "Please enter new number below:\n";</pre>
                cin >> num;
                element.amount = num;
                return &element;
            }
        }
        return NULL;
};
void readFiletoHash(HashTable& hashTable, string filename) {
    ifstream file(filename.c_str());
    if (!file.is_open()) {
        cout << "Failed to open the file\n";</pre>
        return;
    }
    string line;
    while (getline(file, line)) {
        string datestr, type, place;
        int amount;
        stringstream ss(line);
        getline(ss, datestr, ',');
        getline(ss, type, ',');
        getline(ss, place, ',');
        ss >> amount;
        int date = stringToIntH(datestr);
        info data = { date , type, place, amount };
        hashTable.insert(data);
    file.close();
}
void searchMod(HashTable& hashTable) {
    string searchplace;
    int searchdate;
    cin.ignore();
    cout << "Enter the place you want to find: ";</pre>
    getline(cin, searchplace);
    cout << "Enter the date you want to find: ";</pre>
    cin >> searchdate;
    info* result = hashTable.searchHASH(searchplace, searchdate, "Births");
    if (result != NULL) {
        cout << "\n found: " << result->date << ", " << result->type << ", " << result->place << ", " << result->
>amount << endl;</pre>
    }
        cout << "\nPlace " << searchplace << " and date " << searchdate << " was not found or was all Deaths." <<</pre>
endl:
   }
}
struct Node {
    int year;
    string name;
    string region;
    int population;
    Node* left;
    Node* right;
    int height;
```

```
};
//used for the readfromfile function
int stringToInt(const string& str) {
    int result;
    stringstream ss(str);
    ss >> result;
    return result;
}
//constuctor
Node* newNode(int year, string name, string region, int population) {
    Node* node = new Node; // Use new instead of malloc
    node->year = year;
    node->name = name;
    node->region = region;
    node->population = population;
    node->left = NULL;
    node->right = NULL;
    node->height = 1;
    return node;
}
int max(int a, int b) {
    return (a > b) ? a : b;
}
int height(Node* N) {
    if (N == NULL)
        return 0;
    return N->height;
}
Node* rightRotate(Node* y) {
    if (y == nullptr) {
        // Handle null pointer case
        return nullptr;
    }
    Node* x = y \rightarrow left;
    if (x == nullptr) {
        // Handle null pointer case
        return nullptr;
    }
    Node* T2 = x-right;
    x->right = y;
    y \rightarrow left = T2;
    // Update heights
    y->height = std::max(height(y->left), height(y->right)) + 1;
    x->height = std::max(height(x->left), height(x->right)) + 1;
    return x;
}
Node* leftRotate(Node* x) {
    if (x == nullptr) {
        // Handle null pointer case
        return nullptr;
    }
    Node* y = x-right;
    if (y == nullptr) {
        // Handle null pointer case
        return nullptr;
    }
    Node* T2 = y->left;
    y \rightarrow left = x;
```

```
x->right = T2;
    // Update heights
    x->height = std::max(height(x->left), height(x->right)) + 1;
    y->height = std::max(height(y->left), height(y->right)) + 1;
   return y;
}
int getBalance(Node* N) {
   if (N == NULL)
        return 0;
    return height(N->left) - height(N->right);
}
Node* insertNode(Node* node, int year, string name, string region, int population) {
    if (node == NULL) {
        return newNode(year, name, region, population);
   }
    // Compare region first
    if (region < node->region)
        node->left = insertNode(node->left, year, name, region, population);
    else if (region > node->region)
        node->right = insertNode(node->right, year, name, region, population);
    else \{ //Region is the same, compare name type
        if (name < node->name)
           node->left = insertNode(node->left, year, name, region, population);
        else if (name > node->name)
           node->right = insertNode(node->right, year, name, region, population);
        else { //Region and name type are the same, compare year
           if (year < node->year)
                node->left = insertNode(node->left, year, name, region, population);
           else
                node->right = insertNode(node->right, year, name, region, population);
       }
   }
    node->height = 1 + max(height(node->left), height(node->right));
    int balance = getBalance(node);
    if (balance > 1 && year < node->left->year)
        return rightRotate(node);
    if (balance < -1 && year > node->right->year)
        return leftRotate(node);
    if (balance > 1 && year > node->left->year) {
        node->left = leftRotate(node->left);
        return rightRotate(node);
   }
    if (balance < -1 && year < node->right->year) {
        node->right = rightRotate(node->right);
        return leftRotate(node);
   }
    return node;
Node* insertNodeButBirths(Node* node, int year, string name, string region, int population) {
   // If the node is a "Death" node, ignore it
    if (name == "Deaths") {
        return node;
   }
```

```
if (node == NULL) {
       return newNode(year, name, region, population);
   }
   // Compare populations
   if (population < node->population) {
       node->left = insertNodeButBirths(node->left, year, name, region, population);
   }
   else if (population > node->population) {
       node->right = insertNodeButBirths(node->right, year, name, region, population);
   else { // If populations are the same
       // Compare regions
       if (region < node->region) {
            node->left = insertNodeButBirths(node->left, year, name, region, population);
       }
       else if (region > node->region) {
           node->right = insertNodeButBirths(node->right, year, name, region, population);
       }
   }
   // Update height of the current node
   node->height = 1 + max(height(node->left), height(node->right));
   // Get the balance factor of this node
   int balance = getBalance(node);
   // Perform rotations if necessary
   if (balance > 1 && population < node->left->population)
       return rightRotate(node);
   if (balance < -1 && population > node->right->population)
       return leftRotate(node);
   if (balance > 1 && population > node->left->population) {
       node->left = leftRotate(node->left);
       return rightRotate(node);
   }
   if (balance < -1 && population < node->right->population) {
       node->right = rightRotate(node->right);
       return leftRotate(node);
   }
   // If no rotations needed, return the unchanged node
   return node;
void inOrder(Node* root, string& currentRegion) {
   if (root != NULL) {
       inOrder(root->left, currentRegion);
       if (root->region != currentRegion) {
           currentRegion = root->region;
            cout << "REGION : " << currentRegion << endl;</pre>
       cout << root->year << ", " << root->name << ", " << root->region << ", " << root->population << endl;</pre>
       inOrder(root->right, currentRegion);
   }
void readFileToAVLTree(Node **root, string filename,int select) {
   ifstream file(filename.c_str());
   if (!file.is_open()) {
       cout << "Failed to open the file\n";</pre>
       return;
   }
   string line;
   while (getline(file, line)) {
```

}

}

```
string yearstr, name, region;
        int population;
        stringstream ss(line);
        getline(ss, yearstr, ',');
        getline(ss, name, ',');
        getline(ss, region, ',');
        ss >> population;
        int year = stringToInt(yearstr);
        if (select == 1) {
            *root = insertNodeButBirths(*root, year, name, region, population);
        }
        else {
            *root = insertNode(*root, year, name, region, population);
        }
    }
    file.close();
}
Node* search(Node* root, string region, int year, string event) {
    if (root == NULL) {
        return NULL;
    }
    Node* leftResult = search(root->left, region, year, event);
    if (leftResult != NULL)
        return leftResult;
    // Check if region, year, and event match
    if (root->region == region && root->year == year && root->name == event)
        return root;
    // If not matched, continue searching in the right subtree
    return search(root->right, region, year, event);
}
void search(Node* root) {
    string searchRegion, searchEvent;
    int searchYear;
    cout << "Enter the region you want to find: ";</pre>
    getline(cin, searchRegion);
    cout << "Enter the year you want to find: ";</pre>
    cin >> searchYear;
    Node* foundNode = search(root, searchRegion, searchYear, "Births");
    if (foundNode != NULL) {
        cout << "\nNode found: " << foundNode->year << ", " << foundNode->name << ", " << foundNode->region << ",</pre>
" << foundNode->population << endl;</pre>
    }
    else {
        cout << "\nNode with region " << searchRegion << " and year " << searchYear << " for Births not found." <<</pre>
endl;
}
Node* deleteNode(Node* root, string deleteRegion) {
    if (root == NULL) {
        return root;
    }
    if (deleteRegion < root->region)
        root->left = deleteNode(root->left, deleteRegion);
```

```
else if (deleteRegion > root->region)
        root->right = deleteNode(root->right, deleteRegion);
    else {
        root->left = deleteNode(root->left, deleteRegion);
        root->right = deleteNode(root->right, deleteRegion);
        delete root;
        return NULL;
    }
    root->height = 1 + max(height(root->left), height(root->right));
    int balance = getBalance(root);
    //If this node becomes unbalanced, then there are 4 cases
    if (balance > 1 && getBalance(root->left) >= 0)
        return rightRotate(root);
    if (balance > 1 && getBalance(root->left) < 0) {</pre>
        root->left = leftRotate(root->left);
        return rightRotate(root);
    }
    if (balance < -1 && getBalance(root->right) <= 0)</pre>
        return leftRotate(root);
    if (balance < -1 && getBalance(root->right) > 0) {
        root->right = rightRotate(root->right);
        return leftRotate(root);
    }
    return root;
}
Node* findMaxPopulation(Node* root) {
    if (root == NULL)
        return NULL;
    while (root->right != NULL)
        root = root->right;
    return root;
}
Node* findMinPopulation(Node* root) {
    if (root == NULL)
        return NULL;
    while (root->left != NULL)
        root = root->left;
    return root;
}
void modifyPopulation(Node* root) {
    string region;
    int year, newPopulation;
    cout << "Enter the region you want to modify population for:\n ";</pre>
    getline(cin, region);
    cout << "Enter the year: ";</pre>
    cin >> year;
```

```
cout << "Enter the new population: ";</pre>
    cin >> newPopulation;
    if (year < 0 || newPopulation < 0) {</pre>
        cout << "Invalid input! Year and population must be non-negative." << endl;</pre>
        return;
    }
    Node* nodeToUpdate = search(root ,region, year, "Births");
    if (nodeToUpdate != NULL && nodeToUpdate->name == "Births") {
        nodeToUpdate->population = newPopulation;
        cout << "Population for region " << region << " in year " << year << " updated to " << newPopulation <<</pre>
endl;
    }
    else {
        cout << "Node with region " << region << " and year " << year << " not found or there were only deaths" <<</pre>
endl;
}
int main() {
    string region_to_delete;
    string region = " ";
    Node* root = NULL;
    int num, question, most_least;
    int choice;
    HashTable hashTable(100);
    readFiletoHash(hashTable, "data.txt");
   do{
       cout << "\nWhat would you like to do ? \n"</pre>
            "1. Organise by Births\n"
            "2. Organise by region\n"
            "3.Use hashing to search, insert or delete\n"
            "4. Exit\n";
    cin >> question;
    switch (question)
    {
    case(1):
        readFileToAVLTree(&root, "data.txt", question);
            cout << "\nWhat would you like to do ? \n"</pre>
                "1. Show most Births\n"
                 "2. Show least Births\n"
                 "3.Show AVL tree in order\n"
                "4. Exit\n";
            cin >> most_least;
            Node* maxNode = findMaxPopulation(root);
            Node* minNode = findMinPopulation(root);
            switch (most_least)
            {
            case(1):
                 if (maxNode != NULL)
                     cout << "Node with maximum population: " << maxNode->year << ", " << maxNode->name << ", " <<</pre>
maxNode->region << ", " << maxNode->population;
                else
                     cout << "AVL tree is empty.";</pre>
                break;
            case(2):
                 if (minNode != NULL)
                     cout << "Node with minimum population: " << minNode->year << ", " << minNode->name << ", " <<</pre>
minNode->region << ", " << minNode->population;
                else
                     cout << "AVL tree is empty.";</pre>
                break;
            case(3):
                 cout << "In Order Traversal of the created AVL Tree is:\n";</pre>
                 inOrder(root, region);
                break;
```

```
case(4):
            break;
        default:
             cout << "Invalid input\n";</pre>
             break;
        }
    } while (most_least != 4);
    break;
case(2):
    readFileToAVLTree(&root, "data.txt", question);
    do {
        cout << "\nWhat would you like to do?\n"</pre>
             "1. Show AVL tree in order\n"
             "2. Search for birth population given region and year\n"
             "3. Modify birth population given region and year\n"
             "4. Delete a region\n"
             "5. Exit\n";
        cin >> num;
        switch (num) {
        case 1:
             cout << "In Order Traversal of the created AVL Tree is:\n";</pre>
             inOrder(root, region);
             break;
        case 2:
             cin.ignore();
             search(root);
             break;
        case 3:
             cin.ignore();
            modifyPopulation(root);
             break;
        case 4:
             cin.ignore();
             cout << "Give region to delete:\n ";</pre>
             getline(cin, region_to_delete);
             root = deleteNode(root, region_to_delete);
            break;
        case 5:
             cout << "Exiting the program.\n";</pre>
            break;
        default:
             cout << "Invalid option. Please try again.\n";</pre>
        }
    } while (num != 5);
    break;
case(3):
    do {
        cout << "\nMenu:\n";</pre>
        cout << "1. Search for an event\n";</pre>
        cout << "2. Remove an entry\n";</pre>
        cout << "3. Change amount for an event\n";</pre>
        cout << "4. Exit\n";</pre>
        cout << "Enter your choice: ";</pre>
        cin >> choice;
        switch (choice) {
        case 1:
             searchMod(hashTable);
             break;
        case 2: {
             string removed;
             cout << "Enter the place to remove: ";</pre>
             cin.ignore();
              getline(cin, removed);
             cout << removed;</pre>
             hashTable.remove(removed);
             cout << "\nEntry removed.\n";</pre>
             break;
        }
        case 3: {
             string place;
```

```
int date;
                 cout << "Enter the place: ";</pre>
                 cin.ignore();
                 getline(cin,place);
                 cout << "Enter the date: ";</pre>
                 cin >> date;
                hashTable.change_amount(place, date, "Births");
            }
            case 4:
                 cout << "Exiting program.\n";</pre>
                 break;
            default:
                 cout << "Invalid choice. Please try again.\n";</pre>
            }
        } while (choice != 4);
        break;
    case(4):
        cout << "Exiting programm...";</pre>
        break;
    default:
        cout << "Invalid input\n";</pre>
        break;
    }
}while (question != 4);
    return 0;
}
```

# Βιβλιογραφία

- [1] Αθανάσιος Κ. Τσακαλίδης: Δομές Δεδομένων , Πανεπιστήμιο Πατρών https://eclass.upatras.gr/modules/document/index.php?course=CEID1158&openDir=/5e81d479ayvm
- [2] <a href="https://www.geeksforgeeks.org/interpolation-search/">https://www.geeksforgeeks.org/interpolation-search/</a>
- [3] <a href="https://www.geeksforgeeks.org/binary-search/">https://www.geeksforgeeks.org/binary-search/</a>
- [4] https://www.javatpoint.com/interpolation-search-vs-binary-search
- [5] Χρ. Μακρής Σ. Σιούτας: Διαφάνειες e-Class(CEID\_NY233) 2023-2024 https://eclass.upatras.gr/courses/CEID1158/
- [6] Kurt Mehlhorn, Peter Sanders: Αλγόριθμοι και Δομές Δεδομένων-Τα βασικά εργαλεία, εκδόσεις Κλειδάριθμος